

Matriz de costos por tarea

Clasificador de CVs con IA · Entrega Final · Arquitecto de Flujos IA · Rodrigo Benegas

Moneda: USD

Precios: listas públicas de Groq, OpenAI y Anthropic a septiembre 2026 (ver fuentes)

Volumen base: 200 CVs por mes

1. Supuestos de consumo

Concepto	Valor	De dónde sale
Tokens de entrada por clasificación	≈ 1.600	prompt de sistema (≈ 450) + búsqueda (≈ 150) + candidato con resumen del CV (≈ 500) + contexto RAG, 2-4 entradas (≈ 500)
Tokens de salida por clasificación	≈ 350 (tope 700)	JSON con clasificación, justificación y borrador; <code>max_tokens = 700</code> acota el peor caso
Llamadas a la IA por candidato	1	solo entra a la ruta A la ficha en Pendiente con datos completos; aprobar, rechazar o corregir no vuelve a llamar a la IA
Operaciones de Make por candidato (ciclo completo)	≈ 18	ruta A 9 + retrigger 2 · ruta B 5 + retrigger 2; ruta C ≈ 6; ruta D ≈ 6
Candidatos por mes	200	volumen de referencia de una consultora chica; abajo se muestra también 55 y 2.000

2. Matriz por tarea

Tarea	Herramienta / modelo	Tokens in / out	Costo unitario	Vol. mensual	Costo mensual	Por qué esta elección
Detectar fichas nuevas y decidir ruta	Make · trigger + Router	—	2 ops	≈ 260 ejecuciones	incluido en el plan	Lógica determinística; ninguna llamada a la IA para enrutar.
Validar datos incompletos (ruta D)	Make · filtros exist/notexist	0 / 0	0 USD	≈ 20 (10 %)	0,00	Se resuelve sin IA: ahorro directo del 100 % de esos tokens.
Recuperar contexto (RAG)	Notion · Search Objects + Text Aggregator	—	2 ops	180	0,00	La API de Notion no cobra; limitar a 10 entradas acota los tokens de entrada.
Clasificar CV + redactar borrador	openai/gpt-oss-120b vía Groq	1.600 / 350	0,00045	180	0,08	Modelo GPT open-weight de OpenAI con calidad de razonamiento alta, JSON nativo y el precio más bajo de la tabla de alternativas. Groq responde en < 2 s.
Parsear y validar la respuesta	Make · Parse JSON + estructura de datos	—	1 op	180	0,00	Validación estructural sin IA.
Aviso HITL al reclutador	Gmail · Send an Email	—	1 op	180	0,00	Gmail no cobra por API (cuota 500 envíos/día).
Email al candidato (aprobado / rechazado)	Gmail · Send an Email	—	1 op	≈ 180	0,00	Sale el borrador ya generado: no se vuelve a llamar a la IA.
Registro y dashboard	Notion · Create Database Item + vistas	—	1 op por paso	≈ 400	0,00	Trazabilidad y KPIs sin costo de API.

Orquestación (plan de Make)	Make Free (1.000 ops) / Core (10.000 ops)	—	—	≈ 3.600 ops	10,59 (Core)	Con 200 CVs/mes el plan Free no alcanza; hasta ≈ 55 CVs/mes cuesta 0.
Total mensual estimado (200 CVs)					≈ 10,67 USD	La IA es < 1 % del costo: el orquestador domina.

3. Alternativas de modelo para la misma tarea

Costo por clasificación con 1.600 tokens de entrada y 350 de salida, y costo mensual para 200 CVs. Los modelos de OpenAI y Anthropic son alternativas válidas para la consigna (GPT o Claude); gpt-oss-120b es un modelo GPT de OpenAI servido por Groq.

Modelo	USD / 1M entrada	USD / 1M salida	Por CV	200 CVs / mes	Con Batch (– 50 %)	Cuándo conviene
gpt-oss-120b (Groq) — elegido	0,15	0,60	0,00045	0,09	0,045	Default: mejor relación calidad/precio y latencia mínima.
gpt-oss-20b (Groq)	0,075	0,30	0,00023	0,05	0,02	Extracción o formateo simple; juicio de CVs algo más flojo.
GPT-4o mini (OpenAI)	0,15	0,60	0,00045	0,09	0,045	Mismo precio; conviene si ya se usa la plataforma de OpenAI.
GPT-4.1 mini (OpenAI)	0,40	1,60	0,0012	0,24	0,12	Contexto largo (CVs completos de varias páginas).
GPT-5 mini (OpenAI)	0,25	2,00	0,0011	0,22	0,11	Segunda opinión sobre los casos "Revisar".
Claude Haiku 4.5 (Anthropic)	1,00	5,00	0,0034	0,67	0,34	Redacción muy cuidada de los emails; prompt caching – 90 % en el system prompt.
Claude Sonnet 4.5 (Anthropic)	3,00	15,00	0,0100	2,01	1,00	Búsquedas senior donde un falso negativo cuesta caro.

4. Dónde está el ahorro (y cuánto vale)

Palanca	Cómo está implementada	Ahorro estimado
Una sola llamada a la IA por candidato	La ruta A exige Estado = Pendiente; aprobar, rechazar o corregir no reclasifica. Sin esta compuerta, cada edición de la ficha (3-4 por candidato) volvería a llamar al modelo.	≈ 70 % de los tokens
Camino infeliz sin IA	Ruta D detecta datos incompletos con filtros y no consume tokens.	≈ 10 % de las llamadas
Tope de salida	<code>max_tokens = 700</code> : el peor caso cuesta 0,00042 USD por llamada en vez de un JSON sin límite.	acota el riesgo
RAG acotado	Search Objects trae como máximo 10 entradas y solo las del puesto + "General".	– 30 % de entrada vs. inyectar toda la base
Modelo por tarea	gpt-oss-120b para juzgar; los pasos de formateo, validación y enrutado son determinísticos (Make), no IA.	– 85 % vs. usar Sonnet para todo
Batches	Groq y OpenAI ofrecen – 50 % en modo batch (asíncrono). Con el trigger cada 15 minutos la clasificación ya es diferida: se puede migrar la ruta A a un lote nocturno cuando el volumen supere ≈ 2.000 CVs/mes.	– 50 % del costo de IA (≈ 0,45 USD/mes a 2.000 CVs)
Prompt caching	El prompt de sistema y la entrada "General" de la base de conocimiento se repiten en cada llamada (≈ 40 % de la entrada); Groq cobra la entrada cacheada a la mitad.	≈ – 15 % de la entrada

5. Escenarios de volumen

Matriz de costos · Clasificador de CVs con IA · Rodrigo Benegas · septiembre 2026

CVs / mes	Ops de Make	Plan de Make	IA (gpt-oss-120b)	IA con Batch	Total mensual
55	≈ 1.000	Free	0,02	0,01	≈ 0,02 USD
200	≈ 3.600	Core (10.000 ops)	0,09	0,05	≈ 10,7 USD
2.000	≈ 36.000	Core 40.000 ops	0,90	0,45	≈ 30 USD

Conclusión. Con el diseño actual el costo de la inteligencia es marginal (menos de 1 USD hasta 2.000 CVs por mes); el costo real es el orquestador. Por eso las decisiones de ahorro apuntan a reducir *operaciones* (una llamada por candidato, filtros antes de la IA, retrigger acotado a 2 ops) más que a cambiar de modelo. Si se quisiera subir la calidad, la mejora barata es enviar solo los casos "Revisar" (≈ 25 %) a un modelo mayor: +0,05 USD/mes con GPT-5 mini.

6. Fuentes de precios (septiembre 2026)

- Groq — página de precios: gpt-oss-120b 0,15 / 0,60 USD por millón de tokens (entrada cacheada 0,075), gpt-oss-20b 0,075 / 0,30; Batch –50 %.
- OpenAI — página de precios de la API: GPT-4o mini 0,15 / 0,60; GPT-4.1 mini 0,40 / 1,60; GPT-5 mini 0,25 / 2,00; Batch API –50 %.
- Anthropic — página de precios: Claude Haiku 4.5 1 / 5; Claude Sonnet 4.5 3 / 15; Batch –50 %; prompt caching hasta –90 % en lectura.
- Make — planes: Free 1.000 ops/mes e intervalo mínimo 15 min; Core desde 10,59 USD/mes con 10.000 ops.